25_2_Term_Project

2025-11-25

심부전 환자의 사망 여부 예측을 위한 다변량 통계 기법의 적용

1. 초록

본 프로젝트는 심부전 환자 데이터를 대상으로 사망 여부와 관련된 변수들의 구조적 특성을 다변량 통계 기법과 머신러닝 기법을 활용하여 탐색하고, 각 분석 방법의 적용 가능성과 해석상의 차이를 비교하는 것을 목적으로 하였다. 이를 위해 판별분석(LDA, QDA), 다차원 척도법(MDS), 대응분석(MCRA), 그리고 머신러닝 기반 분류 기법인 서포트 벡터 머신(SVM)과 인공신경망(ANN)을 단계적으로 적용하였다. 판별분석과 머신러닝 기반 분류 결과를 비교한 결과, 판별분석과 ANN 에 비해 SVM 이 상대적으로 더 우수한 분류 성능을 보였으며, 특히 비선형 구조를 허용한 RBF 커널 SVM 에서 가장 낮은 오분류율이 관찰되었다. 이는 본 데이터에 선형 분리로는 충분히 설명되지 않는 구조가 존재함을 시사한다. 한편 차원 축소 및 구조 탐색 기법의 결과를 살펴보면, MDS 에서는 사망 여부에 따른 두 집단이 2 차원 지도상에서 명확하게 분리되지는 않았으나, 일부 축을 중심으로 한 방향성 차이는 관찰되었다. 반면 대응분석(MCRA)에서는 사망 여부와 주요 변수 범주 간의 관계가 비교적 명확하게 나타나, 범주형 변수 간 연관 구조를 해석하는 데 유용한 정보를 제공하였다.

2.도입(Introduction)

심부전(Heart Failure)은 심장의 기능 저하로 인해 신체에 필요한 혈액을 충분히 공급하지 못하는 상태를 의미하며, 다양한 생리적 요인들이 복합적으로 작용하는 질환이다. 이로 인해 심부전과 관련된 임상 데이터는 여러 변수들이 동시에 관측되는 다변량 자료의 특성을 가지며, 변수 간 상관 구조와 분포 특성이 분석 결과에 중요한 영향을 미친다. 이러한 점에서 심부전 데이터는 다변량 통계 기법과 분류 분석을 학습하는 데 적절한

사례로 활용될 수 있다. 본 프로젝트에서 Chicco 와 Jurman(2020)의 데이터를 사용하였으며, 원 연구에서는 머신러닝 기법으로 심부전을 예측할 수 있음을 밝혔다. 본 텀프로젝트는 원 논문의 분석 결과를 재현하거나 의학적 결론을 도출하는 데 목적을 두지 않으며, 수업에서 학습한 다변량 분석 기법을 실제 데이터에 적용해 보는 데 초점을 둔다. 이를 통해 이론적으로 배운 분석 방법들이 실제 데이터의 구조를 어떻게 반영하고, 분석 기법에 따라 해석이 어떻게 달라지는지를 경험적으로 이해하고자 한다. 구체적으로 본 연구에서는 판별분석, 다변량 척도법, 대응분석과 같은 전통적인 다변량 통계 기법과 함께, 분포 가정을 필요로 하지 않는 머신러닝 기반 분류 기법을 적용하여 결과를 비교한다. 이러한 접근은 개별 분석 방법의 성능을 평가하기보다는, 데이터의 특성과 분석 기법 간의 관계를 이해하고 각 방법의 장단점을 비교·해석하는 데 목적이 있다. 본 프로젝트는 이를 통해 통계적 이론과 실제 데이터 분석 간의 연결을 강화하는 학습적 의미를 갖는다.

3.데이터 설명(Data Description)

프로젝트에서 사용한 데이터는 Chicco 와 Jurman(2020)의 데이터를 Kaggle 플랫폼에서 다운로드 받아 사용하였다. 본 데이터는 299 명의 심부전 환자에 대한 임상자료로 구성되어 있다. 연령, 혈액 검사 지표, 기저 질환 여부 등 총 13 개의 변수를 포함한다.

변수명	변수 설명	유형	단위
age	환자의 나이	연속형	년(years)
anaemia	빈혈 여부(0=없음, 1=있음)	이산형(이진)	-
creatinine_phosphokinase	혈중 크레아틴 인산화효소(CPK) 수치	연속형	mcg/L
diabetes	당뇨병 여부(0=없음, 1= 있음)	이산형(이진)	-
ejection_fraction	좌측 심실 박출률	연속형	%
high_blood_pressure	고혈압 여부(0=없음, 1= 있음)	이산형(이진)	-
platelets	혈중 혈소판 수(kiloplatelets/mL)	연속형	-
serum_creatinine	혈청 크레이티닌 농도	연속형	mg/dL
serum_sodium	혈청 나트륨 농도	연속형	mEq/L

변수명	변수 설명	유형	단위
sex	성별(0 = 여성, 1 = 남성)	이산형(이진)	-
smoking	흡연 여부(0 = 비흡연, 1= 흡연)	이산형(이진)	-
time	추적 관찰 기간	연속형	일(days)
DEATH_EVENT	사망 여부(0 = 생존, 1= 사망), **반응변수**	이산형(이진)	-

본 프로젝트에서는 수업에서 다룬 다변량 통계 기법의 적용 범위에 따라 연속형 변수만을 설명변수로 선정하였으며, 반응변수는 환자의 사망 여부를 나타내는 DEATH_EVENT 로 설정하여 분석을 수행한다. 따라서 최종 데이터의 구조는 아래와 같다.

```
## [1] 299   7

## [1] "DEATH_EVENT"               "age"
## [3] "creatinine_phosphokinase" "ejection_fraction"
## [5] "platelets"                 "serum_creatinine"
## [7] "serum_sodium"
```

4.데이터 분석(Data Analysis)

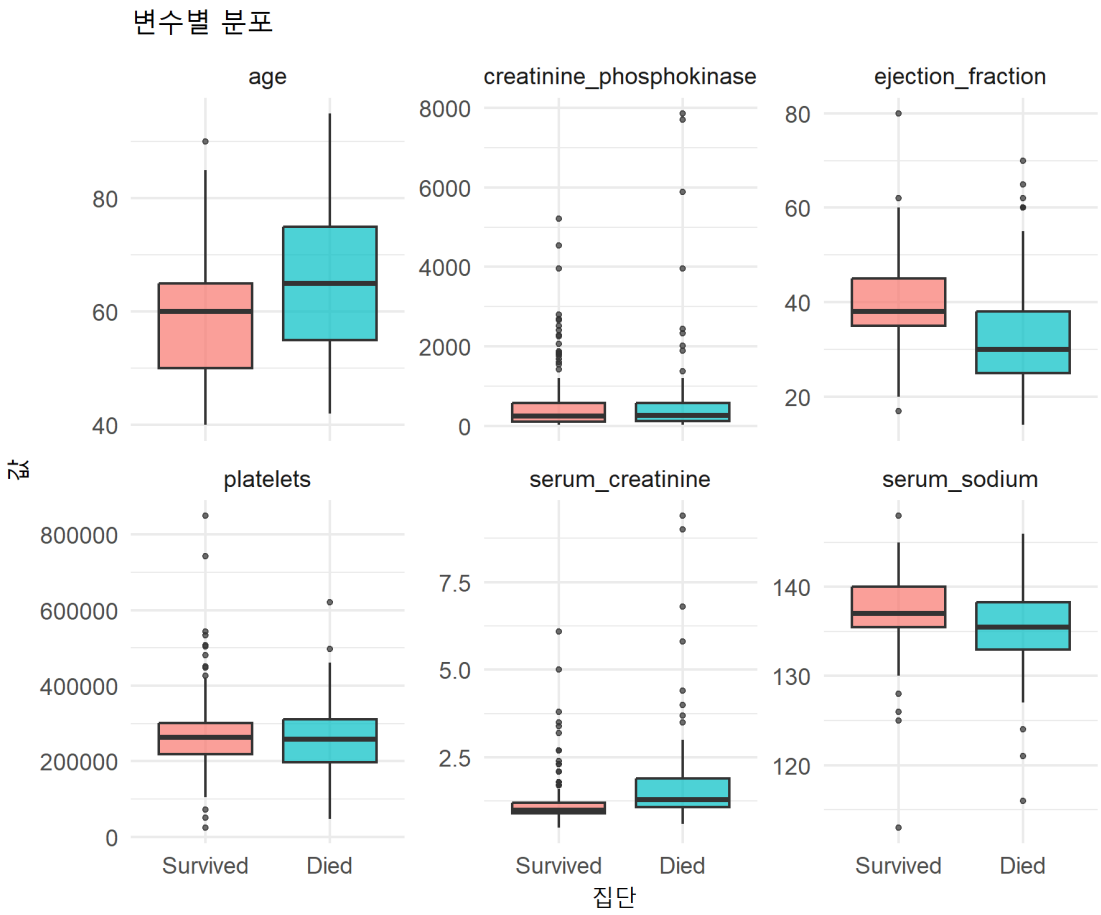
4.1 탐색적 데이터 분석(EDA)

4.1.1 기초 통계량

	mean	std
age	60.834	11.895
creatinine_phosphokinase	581.839	970.288
ejection_fraction	38.084	11.835
platelets	263358.029	97804.237
serum_creatinine	1.394	1.035
serum_sodium	136.625	4.412

기초 통계량을 살펴본 결과 분석에 포함된 변수들은 측정 단위와 값의 범위가 서로 상이함을 확인할 수 있다. 예를 들어, platelets 는 수십만의 값을 가지는 반면, 혈청 크레아티닌 수치(serum_creatinine)나 좌심실 박출률(ejection_fraction)은 상대적으로 작은 범위의 값을 가진다. 이에 따라 본 자료는 표준화가 필요하다고 판단하였으며, 표준화 데이터를 Z 로 정의 하였다.

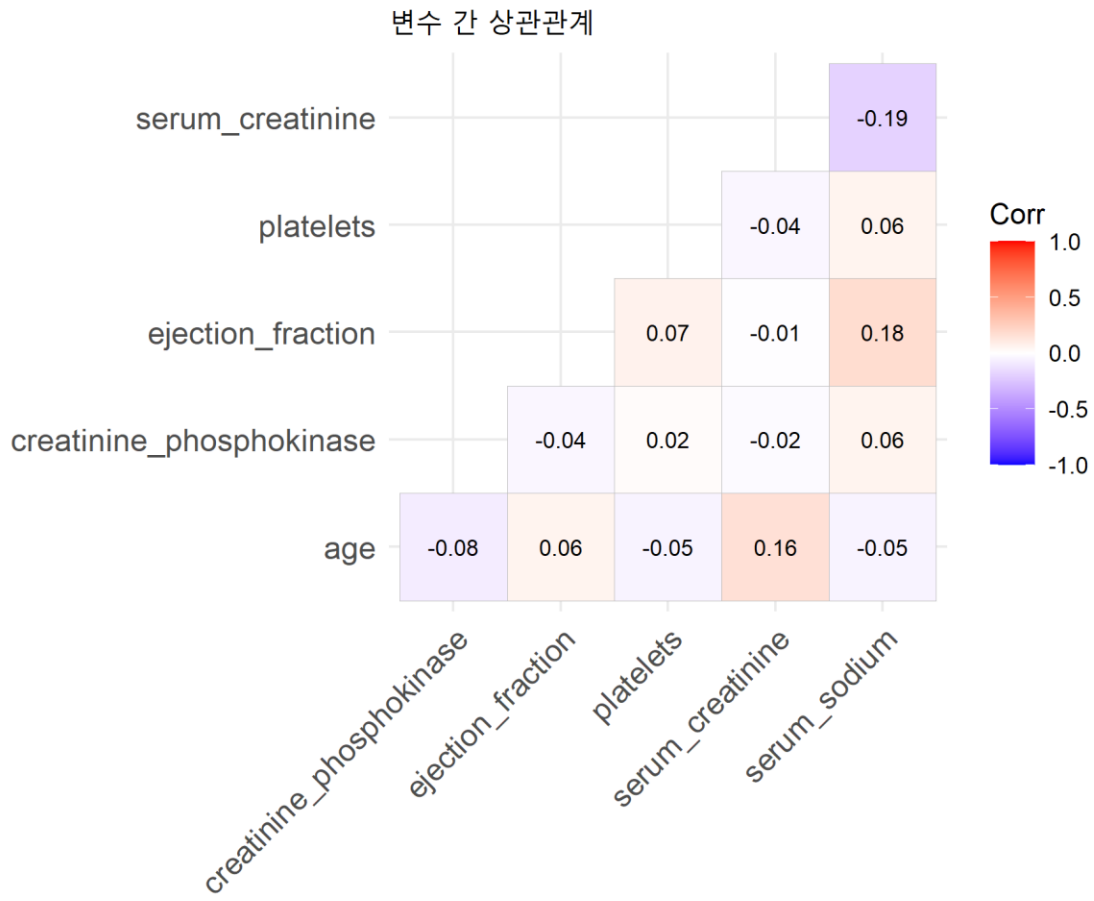
4.1.2 집단 별 Box-Plot



Box-plot 결과, 사망 집단(Died)은 생존 집단(Survived)에 비해 연령(age)이 높고, 좌심실 박출률(ejection fraction)은 낮으며, 혈청 크레아티닌 수치(serum creatinine) 수준은 높은 경향을 보인다. 반면 혈청 나트륨(serum sodium)은 사망 집단에서 상대적으로 낮은 분포를 나타낸다. 이러한 분포상의 차이는 변수들의 선형 결합을 통해 두 집단이 구분될 가능성을 시사한다. 이에 대한 평균의 차이를 수치적으로 나타낸 것은 아래의 표와 같다.

DEATH_EVENT	Survived	Died
age_mean	58.76191	65.21528
creatinine_phosphokinase_mean	540.0542	670.1979
ejection_fraction_mean	40.26601	33.46875
platelets_mean	266657.5	256381.0
serum_creatinine_mean	1.184877	1.835833
serum_sodium_mean	137.2167	135.3750

4.1.3 변수간 상관관계



변수들 간의 상관관계를 살펴본 결과, 대부분의 상관계수가 0.2 이하로 나타나 변수 간의 선형적 관계는 전반적으로 크지 않았다. 이는 각 변수가 비교적 독립적인 정보를 담고 있음을 의미하며, 본 데이터에서는 다중공선성으로 인해 분석 결과가 왜곡될 가능성은 낮은 것으로 판단된다.

4.4 판별분석(Discriminant Analysis)

4.4.1 다변량 정규성 검정

```
##            Test Statistic p.value     Method          MVN
## 1 Henze-Zirkler     2.424  <0.001 asymptotic ✗ Not normal

##            Test Statistic p.value     Method          MVN
## 1 Henze-Zirkler      3.08  <0.001 asymptotic ✗ Not normal
```

다변량 정규성 검정 결과, 사망 여부에 따라 구분된 각 집단에서 다변량 정규성 가정이 모두 기각되었다. 또한 대부분의 개별 변수에서도 정규성 가정이 엄밀하게 충족되지 않는 것으로 나타났다. 이는 본 자료가 판별분석의 이론적 전제인 다변량 정규분포 가정을 충분히 만족하지 못함을 의미한다.

4.4.2 공분산 행렬 동질성 검정

```
##
##  Box's M-test for Homogeneity of Covariance Matrices
##
## data:  data[, -1]
## Chi-Sq (approx.) = 167.15, df = 21, p-value < 0.00000000000000022
```

Box's M 검정을 통한 공분산 행렬 동질성 검정 결과, 사망 집단과 생존 집단 간 분산–공분산 행렬이 동일하다는 귀무가설이 기각되었다. 이는 두 집단이 서로 다른 공분산 구조를 가질 가능성을 시사하며, 특히 선형 판별분석(LDA)의 적용에 있어 해석상의 주의가 필요함을 의미한다.

4.4.3 판별분석의 선택& 가정의 위배

위의 4.4.1 과 4.4.2 의 결과를 바탕으로 할때, 본 자료는 판별분석의 이론적 가정을 엄밀하게 충족하지는 못하였다. 그러나 선행연구에서는 이러한 가정 위배가 판별분석 적용을 반드시 배제해야 할 이유는 아니라고 보고하고 있다(Lachenbruch, 1975; Huberty & Olejnik, 2006). 이에 본 프로젝트에서는 분석 기법의 비교와 이해를 목적으로 LDA 와 QDA 를 모두 적용하여 그 결과를 함께 제시한다.

4.4.4 판별분석(LDA, QDA, 교차검증 방법)

4.4.4.1 LDA

```
##           lcluster
##            Survived Died
##   Survived      186   17
##   Died           54   42

## LDA - APER: 23.74582 %
```

4.4.4.2 QDA

```
##           qcluster
##            Survived Died
##   Survived      164   39
##   Died           30   66
```

```
## QDA - APER: 23.07692 %
```

4.4.4.3 Cross-Validation

```
##
##            Survived Died
##   Survived      184   19
##   Died           58   38

## LDA(cv) - APER: 25.75251 %

##
##            Survived Died
##   Survived      159   44
##   Died           34   62

## QDA(cv) - APER: 26.08696 %
```

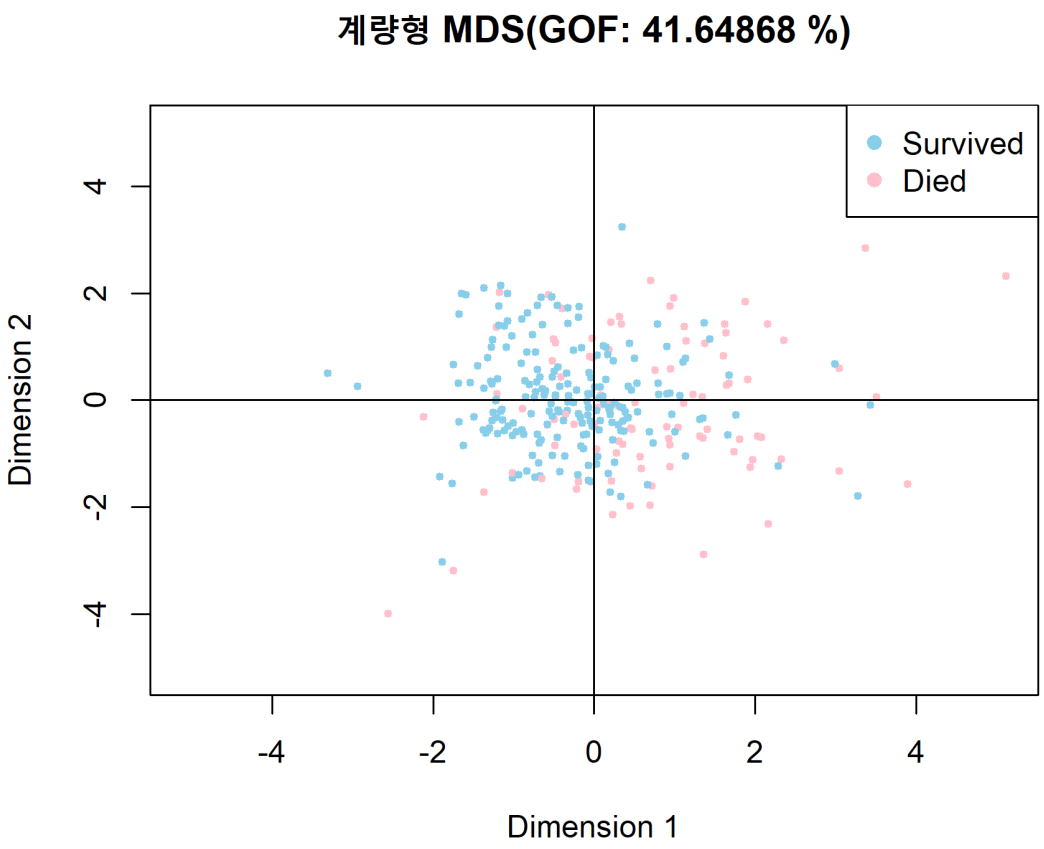
4.4.5 해석

다변량 정규성 및 공분산 행렬 동질성 가정이 엄밀하게 충족되지 않았음에도 불구하고, 판별분석 결과 사망 여부에 따라 두 집단은 일정 수준 이상 구분되는 양상을 보였다. 전체 자료를 이용한 판별분석 결과, 선형 판별분석(LDA)의 APER 는 약 23.75%, 이차 판별분석(QDA)의 APER 는 약 23.08%로 나타나 QDA 가 소폭 더 우수한 분류 성능을 보였다. 이는 집단별 공분산 구조의 차이를 허용하는 QDA 가 본 자료의 분산–공분산 특성을 보다 유연하게 반영한 결과로 해석할 수 있다. 그러나 교차타당성 검증을 적용한 결과, LDA 의 EAER 은 약 25.85%, QDA 의 EAER 은 약 26.08%로 나타나 학습 자료 기준 결과와 달리 성능 순위가 역전되었다.

주목할만한 점은, 교차검증 적용 여부와 관계없이 사망 집단에 대한 분류 성능은 LDA 보다 QDA 에서 일관되게 높게 나타났다는 점이다. 이는 연구의 분석 대상이 심부전 환자의 생존 및 사망과 관련된 임상적 특성임을 고려할 때, 전체 정확도보다 사망 집단에 대한 판별 성능이 더 중요한 해석적 의미를 가질 수 있음을 시사한다. 즉, 사망을 분석의 주요 관심 대상이자 신호(signal)로 간주할 경우, QDA 는 해당 신호에 대해 더 높은 민감도(signal sensitivity)를 보이는 것으로 해석할 수 있다. 반대로 생존 집단을 신호로 정의할 경우에는, 보다 단순한 판별 구조를 갖는 LDA 가 상대적으로 안정적이고 일관된 신호 민감도를 보인다고 해석할 수 있다.

4.5 다변량 척도법(Multi-Dimensional Scaling)

본 자료는 연속형 임상 변수로 구성되어 있으며, 유클리드 거리가 변수 간 수치적 차이를 충분히 반영한다고 판단하였다. 따라서 본 데이터에는 계량형 MDS 를 적용하였다.




```
## GOF: 41.64868 %
```

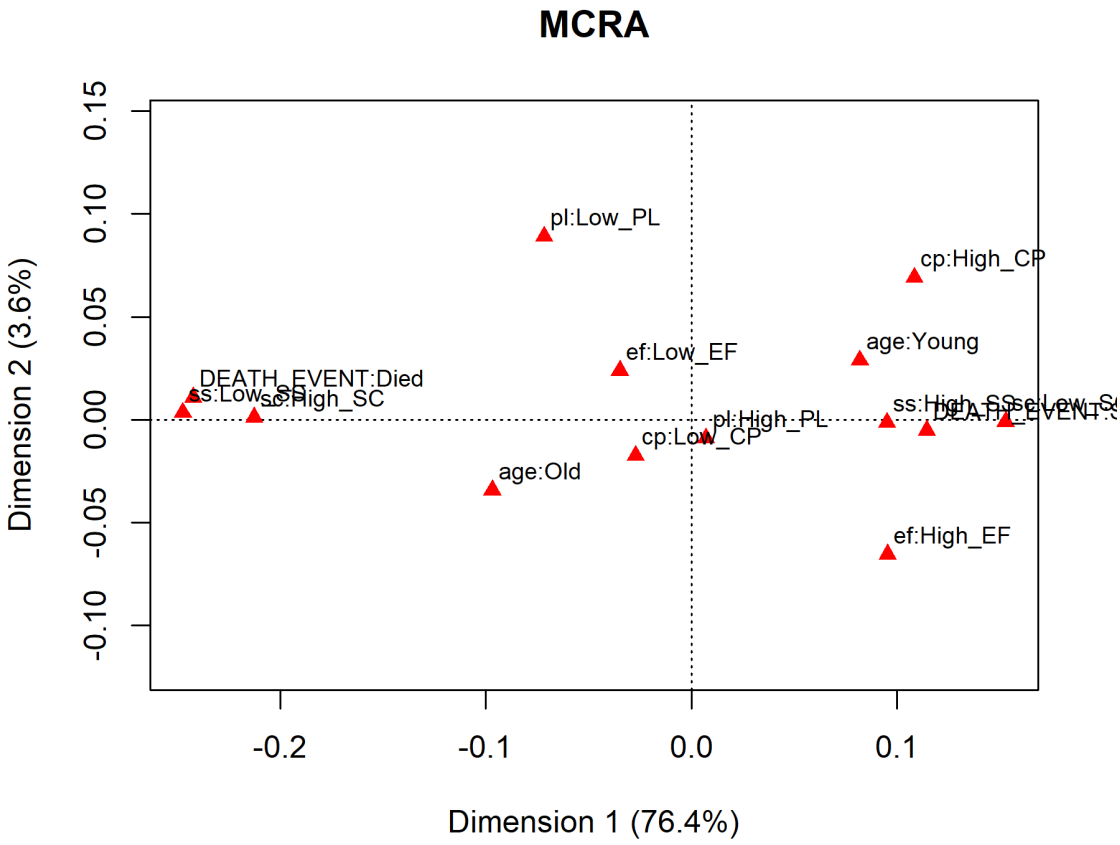
계량형 MDS 결과, GOF 는 약 41.65%로 나타나 2 차원 지도상에서 상대적 위치를 충분히 설명하기에는 제한적이었다. 이에 따라 두 집단은 2 차원 평면상에서 명확하게 분리되지는 않았다. 그러나 Dimension 1 을 기준으로 볼 때 사망 집단은 상대적으로 양(+)의 방향에, 생존 집단은 음(–)의 방향에 더 많이 분포하는 경향을 보여, 두 집단 간 구조적 차이가 일부 존재함을 시사한다.

4.6 대응 분석(Corresspondance Analysis)

4.6.1 대응분석을 위한 범주 변수 생성

본 연구에서는 연속형 임상 변수를 범주형 변수로 변환함에 있어, 임상적 기준으로 선행연구를 참고하였다. 다만, 명확한 임상적 기준이 제시되지 않은 변수의 경우에는 자료의 분포 특성을 반영한 기준(분위수)을 적용하였다. 먼저 연령(age)은 심부전의 발생률과 예후가 고령에서 급격히 변화하는 점을 고려하여, 선행연구에서 흔히 사용되는 기준에 따라 60 세 이하를 Young, 60 세 초과를 Old 로 구분하였다(Roger, 2013). 좌심실 박출률(ejection_fraction, ef)은 수축기 심부전(HFrEF)을 진단하는 표준 기준인 40%를 기준으로, 40% 이하를 Low_EF, 40% 초과를 High_EF 로 범주화하였다(Ponikowski et al., 2016). 혈청 크레아티닌(serum_creatinine, sc)은 신기능 저하를 반영하는 대표적인 지표로, 다수의 임상 연구에서 크레아티닌 수치의 상승이 심부전 환자의 사망 위험 증가와 유의하게 관련됨이 보고되어 왔다. 이에 본 연구에서는 임상적으로 널리 사용되는 기준을 참고하여 1.2 mg/dL 을 기준으로 Low_SC 와 High_SC 로 구분하였다(Smith et al., 2006). 한편 크레아티닌 키나아제(creatinine_phosphokinase, cp)는 심부전 예후와의 관련성이 보고되어 있으나, 특정 임상 cut-off 가 명확히 확립되어 있지 않아, 자료의 분포 특성을 반영하기 위해 상위 위험 구간에 해당하는 0.8 분위수를 기준으로 Low_CP 와 High_CP 로 이분화하였다. 혈청 나트륨(serum_sodium, ss)은 임상적으로 저나트륨혈증의 진단 기준으로 사용되는 135 mEq/L 미만을 기준으로 Low_SS 와 High_SS 로 범주화하였으며(Klein et al., 2005), 혈소판 수치(platelets, pl)는 혈소판 감소증의 임상 기준치인 150,000 미만을 기준으로 구분하여 보조적 변수로 포함하였다(Manzano-Fernández et al., 2011).

4.6.2 대응분석



다중 대응분석(MCRA) 결과, 제 1 차원(Dimension 1)은 전체 변동의 약 76.4%를 설명하며 사망 여부(DEATH_EVENT: Died/Survived)와 관련된 주요 임상 범주들을 양 극단으로 구분하는 핵심 축으로 나타났다. 제 1 차원의 음(–) 방향에는 사망 집단(DEATH_EVENT: Died)과 함께 혈청 크레아티닌 증가(sc: High_SC), 저나트륨혈증(ss: Low_SS), 낮은 좌심실 박출률(ef: Low_EF), 고령(age: Old)과 범주들이 위치해있었다. 반대로 양(+) 방향에는 생존 집단(DEATH_EVENT: Survived)과 함께 낮은 혈청 크레아티닌(sc: Low_SC), 정상 나트륨 수치(ss: High_SS), 높은 좌심실 박출률(ef: High_EF) 및 젊은 연령(age: Young) 범주가 분포하였다. 이러한 범주 배치는 사망 여부를 중심으로 형성된 임상적 위험 구조가 제 1 차원에 일관되게 반영되었음을 시사한다.

4.7 머신러닝(Machine Learning) & 인공신경망(Artificial Neural Network)

앞선 4.4 판별분석에서 본 데이터는 다변량 정규성 가정과 공분산 행렬 동질성 가정을 엄밀하게 충족하지 못함을 확인하였다. 이러한 가정 위배는 판별분석의 이론적 전제와 완전히 부합하지 않는 자료 구조를 시사하며, 판별 결과의 해석에 주의가 필요함을 의미한다. 이에 본 연구에서는 특정 분포 형태를 가정하지 않고 자료로부터 분류 규칙을 학습하는 머신러닝 기반 분류 기법을 추가적으로 적용하였다.

4.7.1 SVM

4.7.1.1 Linear kernel

```
##   gamma cost
## 1   0.5    4

##           predict
## truth      Survived Died
##   Survived      187   16
##   Died           54   42

## EAER(linear): 23.41137 %
```

4.7.1.2 RBF kernel

```
##   gamma
## 3     2

##           predict
## truth      Survived Died
##   Survived      202    1
##   Died            7   89

## EAER(RBF): 2.675585 %
```

Linear 커널을 이용한 SVM 의 경우 LDA 나 QDA 와 비슷한 수준의 성능인 약 23.41%의 기대 오분류율을을 보였다. 이는 사망 여부와 설명변수 간의 관계가 단순한 선형 분류 기준으로는 충분히 설명되지 않음을 의미한다. 반면, RBF 커널을 사용한 경우는 기대 오분류율이 2.67%로 성능이 크게 향상되었다. 이는 데이터 구조 내에 존재하는 비선형적 분리 특성을 RBF 커널이 효과적으로 포착했기 때문으로 해석할 수 있다. 이러한 결과는 본 데이터에서 사망 여부 예측 문제가 선형 판별 문제보다는 비선형 문제에 가깝다는 점을 시사한다.

4.7.2 ANN

```
##           predicted_1
##            Died
```

```
##   Survived   68
##   Died       42

## EAER(ANN - 1 hidden): 38.18182 %

##           predicted_3
##            Died
##   Survived   68
##   Died       42

## EAER(ANN - 3 hidden): 38.18182 %
```

표준화를 적용하지 않은 상태에서 인공신경망을 학습한 결과, 은닉노드 수와 관계없이 모든 관측치가 단일 집단(Died)으로 분류되는 현상이 나타났다. 이에 따른 EAER 는 약 38.18%로, 이는 분류 성능이 아니라 모형이 의미 있는 판별 구조를 학습하지 못하고 단일 클래스에 수렴한 결과로 해석된다. 특히 platelets 변수의 scale 이 다른 변수들에 비해 매우 크기 때문에 다른 변수에 비해 지배적인 영향을 가졌을 가능성이 있다. 따라서 입력 변수에 대한 표준화를 적용한 후 동일한 분석을 다시 수행하였다.

```
##           predicted_1s
##            Died Survived
##   Survived   57       11
##   Died       17       25

## EAER(ANN 1 - hidden): 25.45455 %

##           predicted_3s
##            Died Survived
##   Survived   57       11
##   Died       21       21

## EAER(ANN 3 - hidden): 29.09091 %
```

그 결과, 은닉노드 1 개를 사용한 모형에서 EAER 는 약 25.45%로 감소하였으며, 생존 집단과 사망 집단에 대한 의미 있는 분류가 이루어졌다. 이는 표준화를 통해 각 변수의 영향력이 균형 있게 반영되면서, 인공신경망이 자료 내 분류 구조를 실제로 학습할 수 있게 되었음을 의미한다. 은닉노드 수를 3 개로 증가시킨 경우 EAER 는 약 29.09%로 다시 증가하였다. 이는 모형의 복잡성이 증가함에 따라 학습 자료의 잡음까지 함께 반영되어, 제한된 표본 크기 하에서 일반화 성능이 저하된 결과로 해석할 수 있다. 이는 인공신경망에서 입력 변수의 표준화가 분류 성능에 영향을 미친다는 점을 보여주며, 본 자료와 같이 표본 수가 제한된 상황에서는 과도하게 복잡한 신경망 구조보다 단순한 모형이 더 적절할 수 있음을 시사한다.

4.8 판별분석과 머신러닝 비교

분류	LDA	QDA	SVM(linear)	SVM(RBF)	ANN(표준화)
오분류율	23.74% 25.75%(CV)	23.07% 26.08%(CV)	23.41%	2.67%	25.45% (1 hidden node) 29.09% (3 hidden node)

판별분석(LDA, QDA)과 머신러닝 기법(SVM, ANN)의 분류 성능을 오분류율(EAER/APER) 기준으로 비교한 결과는 위의 표와 같다. 전체 자료를 이용한 경우, LDA(23.74%)와 QDA(23.07%)는 유사한 수준의 분류 성능을 보였으며, QDA 가 소폭 더 낮은 오분류율을 나타냈다. 이는 집단별 공분산 구조의 차이를 허용하는 QDA 가 자료의 분산–공분산 특성을 다소 더 유연하게 반영했기 때문으로 해석할 수 있다. 그러나 교차타당성 검증(CV)을 적용한 결과, LDA 의 오분류율은 25.75%, QDA 는 26.08%로 증가하여 두 방법 모두 일반화 성능이 다소 저하되었으며, 성능 차이 역시 크지 않았다.

선형 커널 SVM 의 경우 오분류율이 23.41%로 나타나, LDA 및 QDA 와 거의 동일한 수준의 분류 성능을 보였다. 이는 본 자료에서 선형 분류 경계에 기반한 방법들이 유사한 성능 한계를 공유하고 있음을 시사한다. 반면 RBF 커널을 적용한 SVM 은 기대오분류율이 가장 낮은 2.67%로 나타나, 비선형 결정 경계를 허용하는 모형이 본 자료의 분류 구조를 가장 효과적으로 포착했음을 보여준다. 다만 해당 결과는 학습 자료 기준 성능이므로, 일반화 성능에 대한 해석에는 주의가 필요하다.

인공신경망(ANN)의 경우, 입력 변수 표준화를 적용한 이후에만 의미 있는 분류 결과를 보였다. 은닉노드 1 개를 사용한 ANN 의 오분류율은 25.45%로 판별분석 및 SVM 에 비해 다소 높은 수준이었으며, 은닉노드를 3 개로 증가시킨 경우에는 오분류율이 29.09%로 오히려 증가하였다. 이는 본 자료와 같이 표본 크기가 제한된 상황에서 모형 복잡성을 증가시키는 것이 반드시 성능 향상으로 이어지지 않으며, 잡음까지 함께 학습하는 과적합 위험이 존재함을 시사한다.

요약하면, 판별분석과 선형 SVM 은 비슷한 수준의 성능을 제공하였으며, 비선형 구조를 허용한 RBF 커널 SVM 이 가장 우수한 분류 성능을 보였다. 반면 ANN 은 전처리 및 모형 구조에 민감하게 반응하여 상대적으로 보수적인 성능을 나타냈다. 이러한 결과는 자료의 구조적 특성과 분석 기법의 가정 및 복잡도 간의 적합성이 분류 성능에 중요한 영향을

미친다는 점을 잘 보여준다. 결론적으로 심부전을 예측하기 위한 기법으로는 RBF 커널을 사용한 SVM 이 가장 적합하다 판단할 수 있었다.

5.결론 및 논의(Result & Discussion)

본 프로젝트에서는 심부전 환자의 사망 여부(DEATH_EVENT)와 관련된 임상적 특성을 다양한 다변량 통계 기법과 머신러닝 기법을 적용하여 분석하였다. 판별분석(LDA, QDA)의 경우 현실 임상 데이터의 특성상 다변량 정규성과 공분산 구조에 대한 가정을 충분히 만족하지 못하였다. 특히 일부 연속형 변수에서 분포의 비대칭성과 이상치가 관찰되어 이론적으로 요구되는 가정이 위배되었으며, 이로 인해 분류 성능과 해석에 일정한 한계가 존재하였다.

다차원 척도법(MDS)을 통해 개체 간 거리 구조를 시각화한 결과, 데이터의 복잡성과 많은 관측치(n=299)로 인해 사망 및 생존 집단이 저차원 공간에서 명확한 군집 형태로 분리되지는 않았다. 이는 사망 여부가 단일한 거리 구조로 설명되기보다는 여러 변수의 복합적인 상호작용에 의해 결정됨을 의미하며, MDS 가 분류가 목적이 아니며, 전반적인 구조 탐색에 유용한 기법이기 때문으로 해석할 수 있다.

대응분석(CRA)에서는 임상적 기준과 분위수를 적용하여 연속형 변수를 범주형 변수로 이산화한 후 분석을 수행하였다. 이를 통해 연속형 변수 간의 복잡한 수치적 관계를 범주 간 상대적 연관 구조로 단순화함으로써, 사망 및 생존 범주와 각 임상 변수 수준 간의 연관성을 보다 직관적으로 해석할 수 있었다. 그 결과, 일부 임상 변수는 사망 집단과 생존 집단 간에 비교적 명확한 분리 양상을 보였으며, 이는 해당 지표들이 사망 여부와 구조적으로 연관되어 있음을 시사한다.

머신러닝 기반 분류 기법 중에서는 SVM(RBF 커널)이 다른 통계적 방법에 비해 가장 우수한 분류 성능을 보였다. 이는 설명변수와 사망 여부 간의 관계가 선형적 분리 기준보다는 비선형적 결정 경계를 통해 더 잘 설명됨을 의미한다. 반면 인공신경망(ANN)은 기대에 비해 상대적으로 낮은 성능을 보였는데, 이는 표본 크기가 제한된 상황에서 모형 복잡성과 하이퍼파라미터 설정에 민감하게 반응한 결과로 해석할 수 있으며, 과적합 가능성을 함께 시사한다.

한편, 본 분석에 사용된 데이터의 원 출처인 Chicco 와 Jurman(2020)의 연구에서도 다양한 머신러닝 기법 중 Random Forest 가 전체 변수 기반 분석에서 가장 우수한 성능을 보였으며, 더 나아가 좌심실 박출률(ejection fraction)과 혈청 크레아티닌(serum creatinine)이라는 소수의 핵심 변수만을 사용한 모델이 전체 변수를 포함한 모델보다 오히려 더 높은 예측 성능을 달성할 수 있음을 보고하였다. 본 프로젝트에서 RBF 커널 SVM 이 가장 좋은 성능을 보였다는 것은, 심부전 환자의 사망 여부가 단순한 직선 형태의 경계로 구분되기보다는 보다 복잡한 비선형 구조를 가진다는 것을 의미한다. 이러한 점은 핵심 변수에 비선형 모델(Random Forest, SVM with RBF kernel , Gradient Boosting)을 적용했을 때 높은 예측 성능을 얻을 수 있음을 보인 Chicco 와 Jurman(2020)의 연구 결과와 맥을 같이한다.

종합하면, 본 프로젝트는 단일한 분석 기법이 모든 데이터 구조에 대해 최적의 해를 제공하지 않으며, 데이터의 특성과 분석 목적에 따라 적절한 방법론을 선택하는 것이 중요함을 보여준다. 특히 실제 임상 데이터에서는 이론적 가정이 강한 전통적 통계 기법보다 데이터의 비선형성과 복잡성을 유연하게 반영할 수 있는 머신러닝 기법이 예측 성능 측면에서 우수할 가능성이 크다는 점을 확인하였다. 이러한 결과는 다변량 통계 기법을 단순히 기계적으로 적용하는 데 그치지 않고, 각 방법이 전제하는 가정과 한계를 고려하여 비판적으로 활용해야 함을 시사하며, 본 프로젝트는 이를 실제 임상 데이터를 통해 경험적으로 확인하였다는 데 의의가 있다.

6.참고문헌(Reference)

최용석 (2020). R 과 함께하는 다변량 자료분석. 경문사.

Chicco, D., & Jurman, G. (2020). Machine learning can predict survival of patients with heart failure from serum creatinine and ejection fraction alone. BMC Medical Informatics and Decision Making, 20(1), 1–16.

Klein, L., O'Connor, C. M., Leimberger, J. D., Gattis, W. A., Piña, I. L., Felker, G. M., ... Gheorghiade, M. (2005). Lower serum sodium is associated with increased short-term mortality in hospitalized patients with heart failure. Circulation, 111(19), 2454–2460.

Manzano-Fernández, S., Pastor-Pérez, F. J., Lozano, T., Franco, F., Giner, M., Bautista-Pavés, A., ... Valdés, M. (2011). Platelet count and long-term mortality in patients with acute heart failure. The American Journal of Cardiology, 108(4), 541–546.

Ponikowski, P., Voors, A. A., Anker, S. D., Bueno, H., Cleland, J. G., Coats, A. J., ... ESC Scientific Document Group. (2016). 2016 ESC Guidelines for the diagnosis and treatment of acute and chronic heart failure. European Heart Journal, 37(27), 2129–2200.

Roger, V. L. (2013). Epidemiology of heart failure. Circulation Research, 113(6), 646–659.

Smith, G. L., Lichtman, J. H., Bracken, M. B., Shlipak, M. G., Phillips, C. O., DiCapua, P., & Krumholz, H. M. (2006). Renal impairment and outcomes in heart failure: Systematic review and meta-analysis. Journal of the American College of Cardiology, 47(10), 1987–1996.

Data source: Heart Failure Clinical Data (Kaggle)

7.R Code

```r
#라이브러리
library(knitr)
library(tidyverse)
library(ggcorrplot)
library(MVN)
library(MASS)
library(biotools)
library(ca)
library(e1071)
library(neuralnet)

#데이터 불러오기
HFP <- read.csv("heart_failure_clinical_records_dataset.csv")
#str(HFP)

#분석 데이터 추출(연속형만 사용)
data <- HFP |>
  dplyr::select(DEATH_EVENT, age, creatinine_phosphokinase, ejection_fraction,
         platelets, serum_creatinine, serum_sodium) |>
  mutate(DEATH_EVENT = factor(HFP$DEATH_EVENT,
                              levels = c(0, 1), labels = c("Survived", "Died
")),
         .keep = "unused")

#str(data)
#colSums(is.na(data)) #결측치 확인인

#집단 변수와 데이터 분리
group <- data$DEATH_EVENT
X <- data[,-1]
```

```r
# 자료의 차원 및 변수
dim(data)
names(data)

#기초 통계량
#summary(X)
apply(X, 2, mean) |> round(3) -> mean
apply(X, 2 , sd) |> round(3) -> std
data.frame(mean,std) |>kable()
#표준화 데이터 Z
Z <- scale(X)

#집단별 박스플롯, 평균분산
data |>
  pivot_longer(cols = -DEATH_EVENT,
               names_to = "variable",
               values_to = "value") |>
  ggplot(aes(x = DEATH_EVENT, y = value, fill = DEATH_EVENT)) +
  geom_boxplot(alpha = 0.7, outlier.size = 0.8) +
  facet_wrap(~ variable, scales = "free_y") +
  theme_minimal() +
  labs(x = "집단",
       y = "값",
       title = "변수별 분포") +
  theme(legend.position = "none",
        strip.text = element_text(size = 9))

cols <- names(data)
cols <- cols[-1]
data |>
  group_by(DEATH_EVENT) |>
  summarise(across(all_of(cols),
                   ~mean(.x, na.rm=T),
                   .names = "{.col}_mean")) |>
  t() |>
  kable()

#상관관계
R <- round(cor(X), 2)
ggcorrplot(
  R,
  type = "lower",
  lab = TRUE,
  lab_size = 3,
```

```r
  title = "변수 간 상관관계")

#판별분석 전 가정 확인
#그룹별 데이터 분리
died <- data |>
  filter(DEATH_EVENT == "Died") |>
  dplyr::select(-DEATH_EVENT) |>
  scale()

survived <- data |>
  filter(DEATH_EVENT == "Survived") |>
  dplyr::select(-DEATH_EVENT) |>
  scale()

res1 <- mvn(died)
res2 <- mvn(survived)
res1$multivariate_normality; res2$multivariate_normality

boxM(data[,-1], data[,1])

#판별분석
LDA <- lda(data$DEATH_EVENT~., data = data)
lcluster <- predict(LDA,data)$class
lct <- table(data$DEATH_EVENT, lcluster)
lct
cat("LDA - APER:", (1-mean(data$DEATH_EVENT==lcluster))*100, "%")

QDA <- qda(data$DEATH_EVENT~., data=data, prior= c(nrow(died), nrow(survived))
/nrow(data))
qcluster <- predict(QDA,data)$class
qct <- table(data$DEATH_EVENT, qcluster)
qct
cat("QDA - APER:", (1-mean(data$DEATH_EVENT==qcluster))*100, "%")

#LDA_CV
LDA_CV <- lda(data$DEATH_EVENT~., data = data, CV=T)
lct_cv <- table(data$DEATH_EVENT, LDA_CV$class)
lct_cv
cat("LDA(cv) - APER:", (1-mean(data$DEATH_EVENT==LDA_CV$class))*100, "%")

#QDA_CV
QDA_CV <- qda(data$DEATH_EVENT~., data=data, prior= c(nrow(died), nrow(surviv
ed))/nrow(data), CV=T)
qct <- table(data$DEATH_EVENT, QDA_CV$class)
qct
cat("QDA(cv) - APER:", (1-mean(data$DEATH_EVENT==QDA_CV$class))*100, "%")
```

```r
#다변량 척도법
D <- dist(Z, "euclidean")
con1 <- cmdscale(D, k=2, eig=T)
x1<-con1$points[,1]
y1<-con1$points[,2]
lim<-c(-max(abs(con1$points)), max(abs(con1$points)))
group_colors <- c("skyblue", "pink")
group_col <- ifelse(group == "Survived", "skyblue", "pink")
plot(x1, y1, xlab="Dimension 1", ylab="Dimension 2", xlim=lim, ylim=lim,
     col = group_col, pch = 19,main = "계량형 MDS(GOF: 41.64868 %)", cex=0.5)
abline(v=0, h=0)
legend("topright", legend = levels(group), col = group_colors, pch = 19)

cat("GOF:", con1$GOF[1]*100, "%")

#대응분석을 위한 데이터 정의
CRA_data <- data |>
  mutate(DEATH_EVENT= DEATH_EVENT,
         age = ifelse(age <= 60, "Young", "Old"),
         cp = ifelse(creatinine_phosphokinase <= quantile(data$creatinine_pho
sphokinase, 0.8), "Low_CP", "High_CP"),
         ef = ifelse(ejection_fraction <= 40, "Low_EF", "High_EF"),
         sc = ifelse(serum_creatinine < 1.2, "Low_SC", "High_SC"),
         ss = ifelse(serum_sodium < 135, "Low_SS", "High_SS"),
         pl = ifelse(platelets < 150000, "Low_PL", "High_PL"),
         .keep = "none")
#str(CRA_data)

#대응분석
mjca(CRA_data) |> plot(main="MCRA")

#머신러닝

# linear kernel
set.seed(1) #동일한 결과를 위한 시드넘버 부여
tune.out=tune.svm(DEATH_EVENT~., data=data, kernel="linear",
gamma = 2^(-1:1), cost=2^(2:4), )
tune.out$best.parameters

svmfit=svm(DEATH_EVENT~., data=data, kernel="linear",
   gamma=0.5, cost=4, scale=T)
#summary(svmfit)

ypred=predict(svmfit, data)
```

```r
table(truth=data$DEATH_EVENT, predict=ypred)
cat("EAER(linear):",(1- mean(data$DEATH_EVENT == ypred))*100, "%")

# RBF kernel
set.seed(1) #동일한 결과를 위한 시드넘버 부여
tune.out1 <- tune.svm(DEATH_EVENT~., data=data, kernel="radial",
gamma = 2^(-1:1))
tune.out1$best.parameters

svmfit1 <- svm(DEATH_EVENT~., data=data, kernel="radial",
   gamma=2, scale=T)
#summary(svmfit1)

ypred1 <- predict(svmfit1, data)
table(truth=data$DEATH_EVENT, predict=ypred1)
cat("EAER(RBF):",(1- mean(data$DEATH_EVENT == ypred1))*100, "%")

#인공신경망
#train-test split
set.seed(1)
ind <- sample(2, nrow(data), replace=T, prob=c(0.60, 0.40))
train <- data[ind==1,]
test <- data[ind==2,]

# 1-hidden-node
model_1 <- neuralnet(DEATH_EVENT~., data=train, hidden=1)
#plot(model_1)
predict_1 <- neuralnet::compute(model_1, test)
idx <- apply(predict_1$net.result, 1, which.max)
predicted_1 <- c('Survived', 'Died')[idx]
#predicted_1
confusion1=table(test$DEATH_EVENT, predicted_1)
confusion1
cat("EAER(ANN - 1 hidden):", (1-sum(diag(prop.table(confusion1))))*100, "%")

# 3-hidden-node
model_3 <- neuralnet(DEATH_EVENT~., data=train, hidden=3)
#plot(model_3)
predict_3 <- neuralnet::compute(model_3, test)
idx <- apply(predict_3$net.result, 1, which.max)
predicted_3 <- c('Survived', 'Died')[idx]
confusion3=table(test$DEATH_EVENT, predicted_3)
confusion3
cat("EAER(ANN - 3 hidden):", (1-sum(diag(prop.table(confusion3))))*100, "%")

#표준화 후 다시 예측
```

```r
# 표준화 data.frame
data_scaled <- cbind(data$DEATH_EVENT, as.data.frame(Z)) |>
  rename(DEATH_EVENT = `data$DEATH_EVENT`)
train1 <- data_scaled[ind==1, ]
test1 <- data_scaled[ind==2, ]

#표준화 & 1-hidden-node
model_1s <- neuralnet(DEATH_EVENT~., data=train1, hidden=1)
#plot(model_1s)

predict_1s <- neuralnet::compute(model_1s, test1)
idx <- apply(predict_1s$net.result, 1, which.max)
predicted_1s <- c('Survived', 'Died')[idx]
#predicted_1
confusion1s=table(test1$DEATH_EVENT, predicted_1s)
confusion1s
cat("EAER(ANN 1 - hidden):", (1-sum(diag(prop.table(confusion1s))))*100, "%")

#표준화 & 3-hidden-node
model_3s <- neuralnet(DEATH_EVENT~., data=train1, hidden=3)
#plot(model_3s)

predict_3s <- neuralnet::compute(model_3s, test1)
idx <- apply(predict_3s$net.result, 1, which.max)
predicted_3s <- c('Survived', 'Died')[idx]
#predicted_1
confusion3s=table(test1$DEATH_EVENT, predicted_3s)
confusion3s
cat("EAER(ANN 3 - hidden):", (1-sum(diag(prop.table(confusion3s))))*100, "%")
```